

Scalanie przy użyciu buforów wielkich

Antoni Czuba 201096 Sem. V Grupa 5A

I. Opis algorytmu

W projekcie zastosowałem scalenie przy użyciu wielkich buforów, działa on w następujący sposób.

1. Etap 1. (Tworzenie przebiegów)

- a. Wczytaj pierwsze nb rekordów z pliku do buforów i posortuj je, używając wydajnej metody sortowania w pamięci (QuickSort, HeapSort, ...), tworząc przebieg (run) o długości nb .
- b. Zapisz przebieg na dysk.
- c. Powtarzaj kroki a i b, aż do osiągnięcia końca pliku

2. Etap 2. (Scalanie)

- a. Scal pierwsze $n-1$ przebiegów, używając n -tego bufora do stworzenia wyjściowego przebiegu, a następnie zapisz go na dysku.
- b. Powtarzaj krok b dla kolejnych przebiegów z pliku, aż do jego końca.
- c. Powtarzaj kroki a i b, aż pozostanie tylko jeden przebieg.

Gdzie

N – liczba rekordów w pliku

b – czynnik blokowania (liczba rekordów w jednym buforze dla jednej strony dyskowej w pamięci operacyjnej)

n – liczba buforów w pamięci operacyjnej dostępnych dla procesu sortowania

II. Implementacja

Jako zbiór danych posłużyły mi tablice rejestracyjne, przechowywałem je w postaci Stringów, o długości 8. Rekordy jakie generowałem miały następującą postać

XXXYYYYY

Wyróżnik miejsca oznaczony 2-3 znakami X składa się z samych liter alfabetu łacińskiego, w przypadku wyróżnika o długości 2 na końcu rekordu dodawana była spacja aby zachować stałą długość rekordu.

Natomiast wyróżnik pojazdu oznaczony 5 znakami Y składa głównie z cyfr arabskich, ale mogą pojawić się tam również litery alfabetu łacińskiego..

Rekordy przechowywałem w pliku .txt aby uprościć debugging i mieć prostszy dostęp do danych, a rekordu w nim były oddzielone znakiem nowej linii.

III. Eksperyment

Eksperyment przeprowadziłem na 4 zestawach danych dla b=5 oraz n=6.

Number of records: 30

Number of disk operations: 12

Number of disk read: 6

Number of disk write: 6

Number of merge phases: 0

Number of records: 31

Number of disk operations: 28

Number of disk read: 14

Number of disk write: 14

Number of merge phases: 1

Pierwsze dwa zestawy danych pomimo bardzo małej różnicy w ilości rekordów dają nam znacznie inne rezultaty, wynika to z tego że pierwszy zestaw został posortowany w całości w pierwszym etapie czyli tworzenia runów, rekordów jest dokładnie tyle ile mieści się w buforach czyli $b*n=5*6=30$, natomiast w drugim przypadku rekordów jest 31 czyli przeprowadzane jest scalanie runów co daje znaczną dodatkową ilość operacji odczytu i zapisu.

Number of records: 150

Number of disk operations: 120

Number of disk read: 60

Number of disk write: 60

Number of merge phases: 1

Number of records: 151



Number of disk operations: 186

Number of disk read: 93

Number of disk write: 93

Kolejne dwa zestawy danych ponownie pomimo bardzo małej różnicy w ilości rekordów dają nam znacznie inne rezultaty, wynika to z tego że pierwszy zestaw po pierwszym etapie składał się z $n-1=5$ runów bo $n*b*(n-1)=6*5*5=150$ co pozwoliło na tylko jeden przebieg scalania, z kolei następny zestaw wyszedł poza granice 151 rekordów, więc wymagał scalania dwóch przebiegów scalania runów,

Porównanie z teorią



Jak widać wzory szacujące ilość operacje dosyć wiernie oddają tendencje i kształt krzywej, natomiast widać wyraźne wzrosty ilości operacji w kluczowych punktach opisanych przeze mnie na wyżej opisanych danych, tj. na górnym wykresie widać wyraźny wzrost przy n^*b , a na dolnym przy $n^*b*1000$.